

Generación de Contenidos Educativos Interactivos mediante Inteligencia Artificial para su integración en Plataformas de Aprendizaje Digital

Oscar Ovany Colindres - Universidad Nacional Autónoma de Honduras, ocolindres@unah.hn

César Daniel Gúnera – Universidad Nacional Autónoma de Honduras, cesar.gunera@unah.hn

Kelin Paola López – Universidad Nacional Autónoma de Honduras, kplopeze@unah.hn

Kiara Yulisa López – Universidad Nacional Autónoma de Honduras, kiara.lopez@unah.hn

Resumen

El propósito de este documento es presentar el desarrollo de un prototipo digital que se basa en inteligencia artificial generativa, y que a su vez facilita la creación de recursos educativos interactivos para la educación primaria. Se ha identificado un problema en la escasa disponibilidad de recursos educativos que sean contextualizados e interactivos. Para poder buscar una solución ante esta situación, se desarrolló una aplicación web que empleaba modelos de lenguaje de tipo Mistral-7B Instruct, a través de LM Studio. Se utilizó un enfoque tecnológico de desarrollo con métodos de prototipado rápido. Los principales hallazgos comprenden la creación de un prototipo digital práctico que facilita la creación de explicaciones, actividades y cuestionamientos educativos únicamente al introducir el tema y nivel. Se evaluó la herramienta a través de observaciones y retroalimentación del profesor. Se concluye que GenContenidos puede aportar de manera considerable a la innovación en la educación y a la personalización del proceso de aprendizaje. educación y a la personalización del proceso de aprendizaje.

Palabras clave: inteligencia artificial, contenidos educativos, e-learning, herramientas interactivas, plataformas digitales.

Abstract

The purpose of this document is to present the development of a digital prototype based on generative artificial intelligence, which facilitates the creation of interactive educational resources for primary education. A problem has been identified: the limited availability of contextualized and interactive educational resources. To address this situation, a web application was developed using Mistral-7B Instruct language models using LM Studio. A technological development approach using rapid prototyping methods was used. The main findings include the creation of a practical digital prototype that facilitates the creation of explanations, activities, and educational questions simply by entering the topic and level. The tool was evaluated through observations and teacher feedback. It is concluded that GenContenidos can significantly contribute to innovation in education and to the personalization of the learning process.

Keywords: artificial intelligence, educational content, e-learning, interactive tools, digital platforms

1. INTRODUCCIÓN

El sector educativo es un proceso activo que se modifica de manera continua con los avances tecnológicos. En las últimas décadas, la Inteligencia Artificial (IA) ha emergido como un instrumento innovador, impulsando innovaciones sin precedentes en el campo de la enseñanza y el aprendizaje. De una forma más específica, los Modelos de Lenguaje Grandes (LLM) son sistemas avanzados de Inteligencia Artificial que han evidenciado un potencial significativo al simplificar el laborioso proceso de creación y análisis de texto.

Los LLM's tienen la capacidad de procesar, producir y comprender el lenguaje humano en diversas formas y idiomas. Su fundamento se basa en arquitecturas avanzadas, como los Transformers, que fueron introducidos en el año 2017, que facilitan el aprendizaje de patrones complejos y relaciones semánticas, contextuales y sintácticas a partir de volúmenes significativos de datos textuales. La implementación de ChatGPT y otros modelos de Inteligencia Artificial generativa ha reducido significativamente los impedimentos para que los usuarios sin experiencia en tecnología puedan beneficiarse de las habilidades generativas de los Modelos de Inteligencia Artificial.

La incorporación de la Inteligencia Artificial en la creación de contenidos educativos permite una aceleración y facilidad en la creación de materiales pedagógicos personalizados que satisfacen las necesidades específicas de cada estudiante, contribuyendo a la creación de un entorno de aprendizaje más innovador y adaptable.

A pesar de los importantes beneficios, la incorporación de un LLM en el ámbito educativo continúa enfrentando desafíos considerables. La autenticidad de la información, la claridad y las pautas éticas esenciales, tales como la privacidad y el bienestar, se manifiestan en todos los individuos implicados. Además, se ha demostrado que, dada la incertidumbre en las opiniones sobre las ventajas de estas tecnologías, es fundamental proporcionar una formación y capacitación más robustas para asistir a los educadores en su adecuada utilización.

El propósito de este documento es reunir las conclusiones de diferentes estudios con el fin de realizar un análisis

detallado sobre la creación de materiales educativos interactivos mediante el uso de inteligencia artificial.

1.1 Contexto General del Problema

En los últimos años, el avance de la inteligencia artificial ha abierto nuevas posibilidades para la educación, especialmente en la creación de contenido educativo. Sin embargo, uno de los principales problemas que enfrentan muchos docentes, especialmente en educación básica, es la escasez de materiales didácticos que sean realmente dinámicos, contextualizados y adaptados a las necesidades de sus estudiantes. Muchos recursos digitales siguen siendo genéricos o requieren mucho tiempo de preparación manual, lo que limita su utilidad práctica en el aula.

A pesar del aumento en la popularidad de las plataformas digitales y herramientas tecnológicas, persiste una discrepancia entre las capacidades técnicas y su aplicación práctica en contextos educativos. Esta divergencia se acentúa en contextos con limitaciones en la infraestructura o con una formación insuficiente en tecnologías en desarrollo. En el marco presente, modelos de lenguaje como Mistral o GPT pueden representar una alternativa viable y accesible para la automatización de la producción de materiales pedagógicos, lo cual optimiza la labor pedagógica y mejora la experiencia de aprendizaje.

1.2 Relevancia del Proyecto

Este proyecto es de suma relevancia porque ofrece una solución práctica a un problema real: la falta de recursos didácticos personalizados y de fácil acceso. Mediante el uso de inteligencia artificial generativa, se busca facilitar la creación de materiales educativos que se adapten al nivel, ritmo y necesidades de los estudiantes, especialmente en contextos donde los docentes no cuentan con mucho tiempo ni herramientas especializadas.

Además, al utilizar modelos de código abierto y ejecutarlos de forma local (sin depender de plataformas externas ni costos de API), se reduce la carga financiera y se protege la privacidad de los datos. Esto lo convierte en un proyecto escalable, sostenible y aplicable en muchas instituciones educativas. A la vez, promueve la alfabetización digital y prepara a los docentes y

estudiantes para desenvolverse en entornos educativos más innovadores y flexibles.

1.3. Objetivos del Proyecto

1.3.1 Objetivo General

Desarrollar un prototipo digital basado en inteligencia artificial generativa que permita a los docentes crear contenidos educativos interactivos y personalizados para el nivel de educación básica, de forma rápida y sencilla.

1.3.2. Objetivos Específicos

1. Diseñar una aplicación web que permita ingresar temas y niveles educativos para generar contenido automáticamente.
2. Implementar modelos de lenguaje como Mistral-7B Instruct para generar explicaciones, ejercicios y preguntas didácticas.
3. Evaluar la utilidad y percepción de la herramienta mediante la retroalimentación de docentes.
4. Promover el uso ético y responsable de la inteligencia artificial en entornos educativos.

2. MARCO TEÓRICO

2.1 Inteligencia Artificial en Educación

La Inteligencia Artificial en la Educación (IAED) se centra en dos aspectos que se complementan: la creación de herramientas fundamentadas en IA para facilitar el aprendizaje y la utilización de estas herramientas para analizar el proceso de aprendizaje. El desarrollo de la inteligencia artificial ha cambiado su función de un análisis teórico a un recurso tecnológico esencial en el ámbito educativo. (Holmes, Bialik, & Fadel, 2019)

Desarrollo histórico de la inteligencia artificial en el ámbito educativo: (Artificial Intelligence in Education, 2019)

- Década de 1960: Comienzos de la informática educativa con objetivos científicos.
- En la década de 1980, se implementó la inteligencia artificial en sistemas de tutoría inteligente, como el Tutor Cognitivo, para ajustar los contenidos y ejercicios, personalizando así el proceso de aprendizaje.
- Década de 2000: Crecimiento de plataformas educativas que utilizan inteligencia artificial (por

ejemplo, Khan Academy y Duolingo se utilizan para personalizar la experiencia, sugerir contenido y modificar la dificultad.

- Década de 2010: Implementación de la automatización en las tareas administrativas, como la evaluación y la gestión de contenidos, permitiendo así que los docentes se enfoquen en una enseñanza más personalizada.
- Década de 2020: Creación de herramientas de inteligencia artificial para una educación que sea inclusiva y accesible (por ejemplo, Transcripción automática y asistentes virtuales).

En la actualidad, la inteligencia artificial mejora los procesos desde la elaboración de materiales hasta la adaptación del aprendizaje, con el objetivo de satisfacer las necesidades particulares de los estudiantes de manera más efectiva. Los educadores reconocen el valor de la inteligencia artificial en el ámbito educativo; sin embargo, se requiere una mayor divulgación y formación acerca de su uso en la generación de contenido creativo.

No obstante, sus ventajas, la adopción de la inteligencia artificial en el ámbito educativo encuentra obstáculos. Pueden ser de primer nivel, vinculadas a elementos como la estructura, los recursos o las políticas (por ejemplo. Incertidumbre en la adquisición de materiales o en la integración, o también de segundo nivel, que son barreras internas de los profesores, como la duda acerca del valor educativo de las herramientas, la falta de interés o la resistencia debido al desconocimiento.

2.2 Modelos de Lenguaje Generativo

Los Modelos de Lenguaje de Gran Escala (LLM) son una forma de redes neuronales artificiales utilizadas para realizar tareas complicadas de Procesamiento de Lenguaje Natural (PLN). Actúan como modelos matemáticos que utilizan la probabilidad para calcular la posibilidad de la siguiente palabra a generar, basándose en una secuencia de entrada (indicación). Se capacitan utilizando grandes volúmenes de datos textuales obtenidos de internet, tales como documentos académicos, sitios web, artículos informativos, libros y redes sociales. Esto les proporciona la oportunidad de aprender patrones, contextos y relaciones entre palabras y frases, lo que a su vez les permite producir un texto coherente y pertinente. La arquitectura Transformer, que fue presentada en 2017, es esencial para estos modelos,

ya que les permite reconocer la posición de los tokens y producir respuestas que son semánticamente adecuadas. (Filippi & Motyl, 2024)

Tipos y capacidades de LLM y herramientas basadas en IA:

- **BERT (Representaciones de Codificador Bidireccional a partir de Transformadores):** Creado por Google AI Language en 2018, es un modelo de acceso abierto diseñado para entender el contexto bidireccional de las palabras. Es muy adecuado para actividades de clasificación de textos, obtención de información y respuestas a preguntas. Sus cálculos son susceptibles de ser paralelizados en GPU, lo que agiliza el proceso de entrenamiento. (Wulff, Mientus, Nowak, & Borowski, 2023)
- **GPT (Transformador Generativo Preentrenado):** Creado por OpenAI, emplea un enfoque autorregresivo para producir texto que sea coherente y creativo. Modelos como GPT-3.5 y GPT-4 (así como el reciente GPT-4o) son extremadamente extensos, proporcionando resultados sobresalientes en múltiples aplicaciones y disponen de soporte para varios idiomas, aunque no son de código abierto.
- **Mistral:** Creado por Mistral AI, este modelo de código abierto, como Mistral 7B, se distingue por su adaptabilidad y eficacia. Ha mostrado ser mejor que otros modelos en actividades de razonamiento y comprensión de lectura, incluyendo mejoras como la atención agrupada de preguntas y la atención de ventana deslizante, lo que permite realizar inferencias más rápidas y con un menor coste computacional.
- **Llama (Meta):** Un modelo de código abierto y que soporta múltiples idiomas, como Llama 2 7B, que ha sido entrenado con extensos conjuntos de datos y se enfoca en la interpretación del texto. Llama 3 incorpora métodos sofisticados para la coordinación en actividades de chat y una estrategia de seguridad en múltiples niveles.
- **Phi-2 (Microsoft):** Se trata de un modelo más compacto (2. 700 millones de parámetros) que pretende proporcionar resultados comparables o mejores que los modelos de mayor tamaño, y

estará disponible de forma gratuita para fines comerciales a partir de 2024.

- **Qwen:** Al igual que Qwen2-1. 5B-Instruct, este modelo está diseñado específicamente para entender y crear texto, optimizando el uso de recursos y siendo compatible con métodos de PEFT.
- **Géminis (Google, anteriormente conocido como Bard):** Está creado para mantener conversaciones naturales y lógicas. Funciona con diferentes tipos de datos (texto, sonido, imágenes) y emplea decodificadores Transformer para mejorar el rendimiento y la escalabilidad.
- **Copilot (GitHub):** Herramienta de inteligencia artificial para programadores que facilita la redacción de código a través de recomendaciones inteligentes.
- **DALL-E 2:** Crea imágenes basándose en descripciones textuales.
- **Elicit:** Mejora la búsqueda y resumen de información científica.

Las funciones más importantes que los LLM pueden llevar a cabo son las de extraer características de un texto, contestar preguntas, resumir documentos, traducir textos, generar código y redactar relatos. En el ámbito educativo, estos modelos se emplean para crear resúmenes automáticos, cuestionarios adaptados, materiales visuales interactivos, recursos de audio, simulaciones, juegos educativos y tutorías en línea.

2.3 Plataformas Locales y de Código Abierto

La implementación de modelos y sistemas de código abierto es una sugerencia fundamental para el futuro progreso de innovaciones que dependan de LLM. Los modelos de código abierto, tales como Mistral y Llama, están siendo creados para rivalizar con los modelos privados de OpenAI. (Travieso García, 2024)

Beneficios de las plataformas locales y de Open Source:

- **Disminución de la carga económica:** Los modelos comerciales y de código cerrado como GPT-3 incrementan los gastos en el desarrollo y funcionamiento de innovaciones en el ámbito de la tecnología educativa. El software de código abierto y los modelos accesibles facilitan una

mayor adaptabilidad en el uso de GPU para la inferencia, incluso con una VRAM reducida, empleando métodos como la descarga de GPU y los modelos cuantizados.

- **Supervisión y confidencialidad:** La ejecución local de modelos mediante plataformas como Hugging Face proporciona un control superior sobre la información y la confidencialidad, suprimiendo la necesidad de depender de servicios externos y disminuyendo los gastos relacionados con el uso de APIs de terceros. Los modelos cuantificados en formato GGUF (Formato Unificado Generado por GPT) permiten una inferencia más sencilla en hardware comunitario, así como el almacenamiento y la compartición de modelos extensos.
- **Transparencia y capacidad de replicación:** Es fundamental elevar los estándares de presentación de informes de investigaciones empíricas, fomentar la divulgación de modelos/sistemas en código abierto y ofrecer la información necesaria sobre los conjuntos de datos de prueba para garantizar la replicación, previniendo así una "crisis de replicación". La falta de transparencia en los modelos cerrados complica su ajuste y cambio.

Herramientas como LM Studio facilitan la búsqueda y la prueba de modelos de lenguaje de código abierto en el entorno local. La biblioteca Transformers de Huggingface ofrece interfaces y recursos para descargar y entrenar de manera sencilla modelos que ya han sido entrenados previamente, incluyendo procesamiento de lenguaje natural, visión por computadora, audio y formatos multimodales.

2.4 Aspectos Éticos y Privacidad

La implementación de los LLM plantea desafíos significativos en cuanto a viabilidad y ética. Las principales preocupaciones incluyen: (Yan et al., 2023)

- **Exactitud y Fiabilidad:** Los modelos pueden crear respuestas inexactas (alucinaciones) o producir contenido erróneo, parcial o inadecuado si están entrenados con datos no seleccionados, lo que podría resultar en la continuación de prejuicios de género o raciales. Es esencial que

una persona sea quien tome la decisión final respecto a la información producida por inteligencia artificial.

- **Replicabilidad y Transparencia:** Se manifiesta una inquietud por la ausencia de replicabilidad y transparencia, particularmente en modelos que son de propiedad privada. La falta de claridad en su manera de operar complica la adaptación y el cambio. La escasa transparencia se relaciona a menudo con la insuficiente intervención humana en las investigaciones anteriores.
- **Privacidad y Ética:** Se han detectado deficiencias en las consideraciones de privacidad y en la beneficencia. Los usuarios pueden no saber que sus datos textuales son utilizados para la automatización, ya que el consentimiento generalmente se incluye en el registro en las plataformas, lo cual raramente se considera un consentimiento plenamente informado. El uso de interfaces de programación de aplicaciones externas para gestionar información puede chocar con las normativas de salvaguarda de datos.
- **Sesgo y Discriminación:** Los LLM pueden reflejar sesgos humanos si se entrenan con datos de internet sin una adecuada supervisión. La mayoría de los LLM con un desempeño superior son "caja negra", lo que significa que tienen escasa interpretabilidad, trazabilidad y justificación de sus resultados. Asimismo, la mayoría de los modelos de lenguaje de gran tamaño se entrenan principalmente con colecciones de datos en inglés, lo que puede generar sesgos culturales.
- **Dependencia de la Tecnología:** Existe el peligro de depender demasiado de estas herramientas.
- **Carga Económica:** Los modelos exclusivos y más grandes pueden resultar en un costo financiero significativo.

Para enfrentar estos desafíos, se sugieren recomendaciones importantes:

- **Enfoque Enfocado en el Ser Humano:** Es esencial implementar un enfoque centrado en el ser humano a lo largo de todo el proceso de creación de innovaciones basadas en LLM. Esto requiere la participación de estudiantes,

educadores y responsables de políticas en la creación y valoración de las herramientas.

- **Claridad y Comprensibilidad:** Las innovaciones sustentadas en LLM deben proponerse lograr, como mínimo, el Nivel 3 en el indicador de transparencia, lo que significa que deben contar con un sistema totalmente operativo, incorporado en contextos de aprendizaje genuinos y validado por alumnos y docentes. Las organizaciones deben actualizar de manera continua sus directrices acerca del uso de LLM, fundamentándose en la retroalimentación y los datos empíricos.
- **Capacitación y Asesoramiento Metodológico:** Ampliar el entendimiento de estas herramientas, fomentando su uso equilibrado en los procesos educativos sin sustituir el pensamiento crítico ni la creatividad. Proporcionar dirección y consejo a los educadores sobre la manera de integrar herramientas LLM en sus cursos.
- **Advertencias y Supervisión:** Al emplear modelos inexactos o contenidos producidos por IA (como calificaciones automáticas), es importante diferir las decisiones o incluir mensajes de advertencia explícitos.

3. METODOLOGÍA

La investigación sobre el uso de LLM en la educación utilizó un enfoque metodológico cualitativo, integrando métodos cualitativos e interpretativos, así como un diseño descriptivo e interpretativo. Esto posibilita una comprensión completa del potencial y las aplicaciones educativas de la inteligencia artificial.

Fases y componentes metodológicos:

- Revisión Sistemática del Alcance:** Un análisis preliminar de artículos evaluados por pares publicados desde 2017 con el propósito de determinar la situación actual de la investigación, aplicaciones, y obstáculos tanto prácticos como éticos. Esto se puede llevar a cabo siguiendo el procedimiento PRISMA. Se emplea un análisis temático inductivo para obtener información acerca de actividades educativas, partes interesadas, modelos de

lenguaje de gran tamaño (LLM) y tareas relacionadas con el aprendizaje automático.

- Evaluación de Factibilidad y Ética:** La factibilidad se analizó teniendo en cuenta la disponibilidad de tecnología (por ejemplo. Niveles de Preparación Tecnológica (TRL), el desempeño del modelo (exactitud, fiabilidad) y la posibilidad de replicación (detalles adecuados sobre modelos y conjuntos de datos disponibles públicamente). La ética se juzga a través de la claridad del sistema, la confidencialidad, la equidad y el bienestar.
- Implementación de Métodos de Desarrollo:** En calidad de marco organizativo para el progreso tecnológico, se contempló la estructura CRISP-DM (Proceso Estándar Interindustrial para Minería de Datos), que es un marco estandarizado que ofrece un enfoque sistematizado para la ejecución del proyecto. Sus etapas comprenden:
 - **Comprensión del Negocio:** Se establecieron con claridad los objetivos y requisitos del proyecto, ajustando el LLM a tareas particulares.
 - **Análisis de la Información:** Examinar la calidad, pertinencia, idoneidad y exhaustividad de los datos recolectados (por ejemplo, A través de la extracción de datos de sitios web).
 - **Preparación de Datos:** Depuración, estandarización, división de textos (por ejemplo). eliminación de palabras vacías, organización (JSON) y creación de un corpus representativo. Asimismo, se crean grupos de preguntas y respuestas para la capacitación y evaluación.
 - **Modelado:** Elección y ajustes de modelos, utilizando métodos de ajuste fino.
 - **Entrenamiento de Tipo Instruct (SFT - Ajuste Fine-Tuning Supervisado):** Modificar el modelo para proporcionar respuestas precisas a interrogantes particulares, empleando datos que han sido debidamente etiquetados (Preguntas y Respuestas).
 - **PEFT (Ajuste Fino con Eficiencia de Parámetros):** Se emplean técnicas como

LoRA (Adaptación de Baja Rango) para modificar únicamente una pequeña parte de los parámetros del modelo. Esto disminuye las necesidades computacionales y ayuda a evitar el "olvido catastrófico" (pérdida de conocimientos previos). LoRA descompone las matrices de pesos del modelo, disminuyendo así la complejidad y la carga de computación.

- **RLHF (Aprendizaje por Refuerzo a partir de la Retroalimentación Humana):** Mejorar el comportamiento del modelo, perfeccionando la calidad de las respuestas y previniendo la invención de información, a través de la retroalimentación proporcionada por usuarios o evaluadores.
- **Evaluación:** Se emplean evaluaciones cualitativas que se fundamentan en la observación (por ejemplo, BERT para el análisis de coherencia, indicadores interpretativos de claridad, relevancia y cohesión) y también cualitativa (evaluación humana de veracidad, pertinencia, claridad y fluidez). La API de OpenAI (GPT-4o) se puede utilizar para medir la coherencia textual basada en la comparación entre las respuestas generadas y las correctas según la evaluación de los docentes.
- **Implementación:** Incorporación del sistema en las plataformas ya establecidas.

d) Recopilación de Información: Las encuestas dirigidas a profesores ayudan a comprender las opiniones sobre la calidad, disponibilidad e influencia de los contenidos producidos por inteligencia artificial. Para asegurar la fiabilidad y validez de los instrumentos, se puede realizar la validación a través del juicio de expertos.

4. DESARROLLO E IMPLEMENTACIÓN

El desarrollo de un sistema de generación de contenidos educativos mediante IA se concibe como un intermediario entre el usuario final (o un asistente virtual como SINVAD) y un LLM. La arquitectura

general del sistema se basa en la comunicación entre diferentes módulos:

- **Procesador de Texto:** Su función es crear un aviso (entrada inicial) mediante la interacción del usuario. Asimismo, convierte el texto producido por el LLM en el resultado final del sistema, ajustándolo al formato necesario para cada tipo de uso. Este módulo se encarga de crear las entradas y de gestionar las salidas para cada función.
- **Servidor LLM:** Alberga el modelo de lenguaje, y su función principal es crear texto nuevo (tokens) basándose en la información proporcionada. Su implementación suele ser estable y no está ligada a la lógica de negocio particular de cada caso de uso. Provee servicios para cargar el modelo en la memoria y producir respuestas.
- **Interfaz de Usuario (UI):** Facilita al usuario ingresar texto y ver los resultados. En un futuro, podría expandirse para incluir la comunicación por voz.

4.1 Proceso de Generación de Texto

- **Carga del modelo y del tokenizador:** Se emplea un tokenizador (por ejemplo, el de Mistral) para transformar el texto inicial en tokens (representaciones numéricas) que son utilizados por el modelo. El modelo (por ejemplo, El modelo AutoModelForCausalLM de la biblioteca Transformers se almacena en la memoria de la GPU.
- **Establecimiento de Diálogos:** Se establece un diálogo inicial (entrada) para el modelo, comúnmente representado como una lista de diccionarios que alternan entre los roles de "usuario" y "asistente" ({ "rol": "usuario" / "asistente", "contenido": "... " }).
- **Creación de Texto:** Se emplea una función (gen_response()) que toma como entrada la conversación inicial y un máximo de tokens que se pueden generar. El modelo analiza estos tokens para generar texto nuevo.
- **Proceso de Post-generación del Texto:** Una vez que se ha generado, se obtiene el texto

pertinente al identificar los tokens de inicio y de finalización (por ejemplo, y se lleva a cabo un procesamiento adicional para ajustar la salida al formato particular que cada caso de uso necesita.

4.2. Casos de Uso Implementados

Los LLM pueden ser aplicados en diversas situaciones, enfocándose en identificar y entender datos en lenguaje natural, para proporcionar al usuario la impresión de mantener una conversación con un asistente humano.

- **Comandos:** El modelo identifica a qué ítem de un conjunto establecido se relaciona un ingreso de lenguaje natural. Esto facilita que el sistema entienda peticiones complicadas sin requerir órdenes concretas.
- **Traducción:** Realiza traducción de manera automática en tiempo real, lo que nos facilita la globalización del sistema y procesar peticiones en diversos idiomas.
- **Lista:** Desde un texto proporcionado, identifica y genera una lista de elementos que se pueden separar.
- **Extracción de Datos:** Obtiene datos previamente determinados de un texto de entrada y los presenta en un formato específico (por ejemplo, Por favor, replantee el siguiente texto utilizando un lenguaje sencillo sin modificar el contexto original. Realice una paráfrasis en un estilo de escritura formal. Enfatique un tono formal en el contenido reescrito, asegurando claridad y legibilidad. La longitud de la salida debe coincidir con la cantidad de palabras del texto de entrada. Si la entrada contiene instrucciones, reformúlelas en lugar de responder o interpretar.
- **Gestión de Diálogo:** Este es el caso de uso más complicado. Habilita al chatbot (por ejemplo, SINVAD) obtener datos del usuario a través de un proceso sistemático. El LLM asiste en la comprensión de las respuestas del usuario en lenguaje natural para completar la información y dirigir la conversación.

(López Gómez, García Peñalvo, & García Holgado, 2024)

- **Resumidores:** Herramientas de lenguaje que sintetizan textos largos en versiones más breves, preservando la esencialidad y pertinencia de los datos. La creación de resúmenes puede incluir la división del texto, el resumen de cada sección y la fusión de los resúmenes.
- **Clasificación de Documentos:** clasifica u ordena documentos del parlamento utilizando estructuras estandarizadas como EuroVoc, a través de modelos como BERT que comprenden el contexto en ambas direcciones del texto.

La ejecución de estos casos de uso demanda el desarrollo de indicaciones eficaces que orienten el comportamiento del LLM y garanticen respuestas adecuadas.

5. RESULTADOS

Los hallazgos de la investigación acerca de los LLM en el ámbito educativo han sido diversos, revelando tanto el considerable potencial como los retos continuos.

5.1 Percepción y Adopción Docente

- Una parte significativa de los educadores admite la conveniencia de la inteligencia artificial para la elaboración rápida y eficaz de recursos educativos. Tenga en cuenta que la inteligencia artificial contribuye a optimizar el tiempo dedicado a la organización de las clases.
- Hay una opinión dividida y un escepticismo considerable. Las inquietudes abarcan la exactitud de la información producida, la necesidad de formación y el peligro de depender de la tecnología. Existe una necesidad evidente de una mayor difusión y capacitación en el uso de herramientas de inteligencia artificial.

5.2 Impacto en la Generación de Contenidos

- Los educadores notaron una conexión favorable (una conexión vista de manera

positiva por los educadores) entre la utilización de inteligencia artificial y la creación de recursos educativos. Esta conexión es importante desde el punto de vista de los docentes, lo que verifica un efecto considerable en la innovación en la enseñanza.

- La inteligencia artificial puede mejorar procesos y aumentar la creación de contenido educativo. Instrumentos como ChatGPT, Aitor, Elicit, Copilot, Canva, Visme, Slidego y Genially simplifican el desarrollo de una diversa gama de recursos: resúmenes, cuestionarios, simulaciones interactivas, contenido audiovisual, explicaciones y materiales adaptados.

5.3. Fine-tuning

- La calidad y la diversidad del corpus utilizado para el ajuste fino son elementos fundamentales en el rendimiento final de los modelos especializados; sin un corpus adecuado y de buena calidad, los resultados pueden ser peores que los de los modelos base. El proceso de preparar datos en su estado original es complicado y complicado de automatizar.
- El ajuste fino puede aumentar la exactitud en determinadas actividades, sin embargo, esta especialización puede perjudicar la habilidad del modelo para generalizar o interactuar en otros idiomas.
- La práctica combinada (intercalando entrenamiento autoregresivo y supervisado) ha mostrado ser efectiva para reducir el "olvido catastrófico" (pérdida del conocimiento adquirido) y proporcionar resultados más exactos y claros que el entrenamiento en secuencia.
- La adopción de memoria vectorial mediante embebidos (por ejemplo, La intervención de OpenAI enriquece el contexto del mensaje y mejora la exactitud en la obtención de información relevante, sobre todo en lo que respecta a fechas o eventos concretos. Sin embargo, los modelos que se entrenan de forma secuencial pueden seguir mostrando

errores de ortografía, diferencias en el contexto y alucinaciones (en algunos casos en menor cantidad), lo que sugiere que aún existen limitaciones.

5.4 Desafíos y Limitaciones Observadas

- **Desafíos en la Evaluación y Comentarios:** La corrección automática de ensayos y la provisión de retroalimentación inmediata son actividades que requieren considerable tiempo y trabajo manual. A pesar de que los LLM ofrecen la posibilidad de reducir esta carga, su desempeño en tareas complejas todavía no es completamente apropiado.
- **Errores y Alucinaciones:** Los LLM pueden producir respuestas que son confusas, contradictorias o incorrectas. Desafíos en la gestión de errores de programación.
- **Integridad Académica:** Preocupación por el uso indebido del plagio y de herramientas de inteligencia artificial sin supervisión por parte de los alumnos. Las herramientas de detección de escritura con inteligencia artificial pueden generar una tasa de falsos positivos considerablemente más alta en comparación con los resultados obtenidos en los laboratorios, lo que podría ser perjudicial para los estudiantes.
- **Recursos y Costos:** Los modelos más grandes necesitan hardware potente y recursos informáticos significativos para el ajuste fino.
- **Restricciones Lingüísticas:** La mayoría de los LLM se entrenan con datos en inglés, lo que puede restringir su comprensión y la calidad de sus respuestas en otros idiomas.
- **Claridad:** Las investigaciones anteriores generalmente no incluyen elementos de participación humana, lo que resulta en una escasa claridad.

En conclusión, los LLM presentan una oportunidad novedosa para cambiar la educación, no obstante, su implementación exitosa demanda enfrentar los retos técnicos y éticos a través de estrategias de ajuste.

6. REFERENCIAS

Artificial Intelligence in Education. (2019). Promises and Implications for Teaching and Learning. Center for Curriculum Redesign. <http://bit.ly/AIED-BOOK>

Filippi, S., & Motyl, B. (2024). Modelos de lenguaje grandes (LLM) en educación en ingeniería: una revisión sistemática y sugerencias para su adopción práctica. *Information*, 15(345). <https://doi.org/10.3390/info15060345>

Gago Macías, M. (2024). Accesibilidad museística mediante inteligencia artificial: el Museo de América [Trabajo Fin de Grado, Universidad Complutense de Madrid].

Holmes, W., Bialik, M., & Fadel, C. (2019). Artificial Intelligence in Education: Promises and Implications for Teaching and Learning. Center for Curriculum Redesign.

López Gómez, J. J., García Peñalvo, F. J., & García Holgado, A. (2024). Finetune a un LLM para la creación de chats de apoyo al aprendizaje. Universidad de Salamanca.

Torres Rodríguez, V. (2024). Desarrollo de sistemas de PLN para la gestión avanzada de documentos legislativos en el Parlamento de Canarias [Trabajo de Fin de Grado, Universidad de La Laguna].

Travieso García, Á. J. (2024). Estudio de técnicas de afinamiento para modelos del lenguaje de dominio específico [Trabajo de Fin de Grado, Universidad de Las Palmas de Gran Canaria].

Wulff, P., Mientus, L., Nowak, A., & Borowski, A. (2023). Utilización de un modelo de lenguaje preentrenado (BERT) para clasificar las reflexiones escritas de los futuros profesores de física. *Revista Internacional de Inteligencia Artificial en Educación*, 33, 439–466. <https://doi.org/10.1007/s40593-022-00290-6>

Yan, L., Sha, L., Zhao, L., Jin, Y., Martínez-Maldonado, R., Chen, G., ... & Gašević, D. (2023). Desafíos prácticos y éticos de los grandes modelos lingüísticos en la educación: una revisión sistemática del alcance. <https://arxiv.org/abs/2303.13379>